



# Revisão Completa: Análise de Algoritmos

## Notação Big O e Estruturas de Dados

**Objetivo:** Dominar completamente a análise de complexidade computacional

**Foco:** Conceitos fundamentais com exemplos práticos e comparativos

**Nível:** Didático e passo a passo para qualquer pessoa entender

# Roteiro de Aprendizagem

## Parte I: Fundamentos da Análise

1. O que é Análise de Algoritmos?
2. Por que Big O é Importante?
3. Matemática por Trás da Notação

## Parte II: Notação Big O Detalhada

4. Definição Formal e Intuição
5. Classes de Complexidade Principais
6. Exemplos Práticos Passo a Passo

## Parte III: Estruturas de Dados

7. Homogêneas vs Heterogêneas

# O que é Análise de Algoritmos?

**Definição Simples:** É como medimos a "eficiência" de um algoritmo, ou seja, quanto tempo e memória ele precisa para resolver um problema.

## Analogia do Mundo Real

Imagine que você precisa **organizar 1000 livros** em uma estante:

### Método Lento

- Pegar um livro por vez
- Procurar a posição certa
- Inserir e reorganizar tudo
- **Tempo:** Horas inteiras

### Método Rápido

- Separar por categoria primeiro

## Por que Big O é Crucial?

### Cenário Real: Sistema de E-commerce

Situação: Você tem um site com produtos para buscar

Usuários	Algoritmo Ruim $O(n^2)$	Algoritmo Bom $O(\log n)$
100 produtos	0.01 segundos	0.001 segundos
1.000 produtos	1 segundo	0.003 segundos
10.000 produtos	100 segundos ⚠	0.013 segundos ✓
100.000 produtos	2.8 horas 💣	0.017 segundos ✓

**Conclusão:** Um algoritmo ruim pode **quebrar** seu sistema quando ele cresce!



# Matemática por Trás (Passo a Passo)

## Etapa 1: O que Estamos Medindo?

Entrada: Tamanho do problema  $\rightarrow n$

Saída: Número de operações  $\rightarrow f(n)$

## Etapa 2: Função de Crescimento

Para um algoritmo que percorre uma lista:

Lista de tamanho  $n = [1, 2, 3, \dots, n]$

Operações necessárias =  $n$  comparações

Portanto:  $f(n) = n$

## Etapa 3: Comportamento Assintótico

## Definição Formal de Big O

Big O Notation:  $f(n) = O(g(n))$  se existem constantes positivas  $c$  e  $n_0$  tais que:

$$f(n) \leq c \cdot g(n) \text{ para todo } n \geq n_0$$

### Tradução em Português Simples

"A função  $f(n)$  cresce **no máximo** tão rápido quanto  $g(n)$ , ignorando constantes e termos menores."

### Exemplo Matemático Completo

Dado:  $f(n) = 5n^2 + 3n + 7$

Queremos provar:  $f(n) = O(n^2)$

Escolhemos:  $g(n) = n^2, c = 6, n_0 = 10$

# Problemas Computacionais por Classe

## Classe O(1) - Problemas Constantes

Características: Solução não depende do tamanho da entrada

### Exemplos Práticos:

- Calcular área de círculo:  $A = \pi \times r^2$
- Verificar se número é par:  $n \% 2 == 0$
- Acessar elemento de array: `arr[index]`
- Operações em pilha: `push()` , `pop()`

```
def eh_par(numero):  
    return numero % 2 == 0 # Sempre 1 operação  
  
# Funciona igual para qualquer número:
```

## Classe $O(\log n)$ - Problemas Logarítmicos

Características: Dividem problema pela metade a cada passo

### Exemplos Práticos:

- Busca binária em array ordenado
- Operações em árvore binária balanceada
- Algoritmos "dividir para conquistar"

```
def busca_binaria(lista, alvo):  
    esquerda, direita = 0, len(lista) - 1  
  
    while esquerda <= direita:  
        meio = (esquerda + direita) // 2  
  
        if lista[meio] == alvo:  
            return meio  
        elif lista[meio] < alvo:
```



## Classe $O(n)$ - Problemas Lineares

Características: Precisam examinar cada elemento uma vez

### Exemplos Práticos:

- Encontrar maior elemento em lista
- Somar todos elementos de array
- Busca linear em lista não ordenada
- Percorrer lista ligada

```
def encontrar_maior_menor(lista):  
    if not lista:  
        return None, None  
  
    maior = menor = lista[0]    # 2 operações  
  
    for elemento in lista[1:]:  # n-1 iterações
```

## Classe $O(n^2)$ - Problemas Quadráticos

Características: Comparam cada elemento com todos os outros

### Exemplos Práticos:

- Bubble Sort, Selection Sort, Insertion Sort
- Encontrar todos os pares em lista
- Multiplicação de matrizes simples
- Verificar duplicatas (algoritmo ingênuo)

```
def encontrar_pares_soma(lista, soma_alvo):  
    pares = []  
    n = len(lista)  
  
    for i in range(n):  
        # n iterações  
        for j in range(i+1, n):  
            # n-1, n-2, ..., 1 iterações  
            if lista[i] + lista[j] == soma_alvo:
```

# ⚡ Otimização e Trade-offs

## Caso Prático: Sistema de Busca

Cenário: Você tem um site com 1 milhão de produtos

### ✗ Abordagem Ingênua

```
def buscar_produto(produtos, nome):  
    for produto in produtos: # O(n)  
        if produto.nome == nome:  
            return produto  
    return None
```

### ✓ Abordagem Otimizada

```
# Pré-processamento O(n log n)  
produtos_dict = {p.nome: p for p in produtos}  
  
def buscar_produto(nome): # O(1)  
    return produtos_dict.get(nome)
```

# Exercício Prático Completo

## Problema: Sistema de Notas de Alunos

### Requisitos:

1. Armazenar notas de 1000 alunos
2. Calcular média da turma
3. Encontrar maior e menor nota
4. Buscar nota de aluno específico

## Solução Passo a Passo

```
class SistemaNotas:  
    def __init__(self):  
        self.notas = {} # Hash table: O(1) para busca
```

# Resumo Comparativo Final

## Guia de Decisão Rápida

Se você precisa de...	Use...	Complexidade
Acesso rápido por posição	Array	$O(1)$
Busca rápida por chave	Hash Table	$O(1)$
Dados sempre ordenados	Árvore Balanceada	$O(\log n)$
Inserção/remoção frequente	Lista Ligada	$O(1)$ início
Menor uso de memória	Array	Menos overhead

## Algoritmos por Problema

Problema	Algoritmo Recomendado	Complexidade
Ordenação pequena ( $n \leq 50$ )	Insertion Sort	$O(n^2)$

# Checklist de Domínio

## Você deve saber identificar:

- [ ]  $O(1)$ : Operações que não dependem do tamanho
- [ ]  $O(\log n)$ : Algoritmos que dividem o problema
- [ ]  $O(n)$ : Algoritmos que percorrem dados uma vez
- [ ]  $O(n \log n)$ : Algoritmos dividir-e-conquistar eficientes
- [ ]  $O(n^2)$ : Algoritmos com loops aninhados
- [ ]  $O(2^n)$ : Algoritmos exponenciais (evitar!)

## Você deve saber escolher:

- [ ] Array vs Lista Ligada para diferentes cenários
- [ ] Estruturas homogêneas vs heterogêneas
- [ ] Trade-offs entre tempo e memória

## Próximos Passos

### Para Praticar Mais:

1. **Implemente** cada algoritmo mostrado
2. **Meça** tempo real de execução
3. **Compare** com as previsões teóricas
4. **Otimize** algoritmos  $O(n^2)$  para  $O(n \log n)$

### Para Aprofundar:

- Análise amortizada
- Complexidade de espaço
- Algoritmos paralelos
- Estruturas de dados avançadas

## Conclusão

Você agora domina:

- ✓ Notação Big O e suas classes principais
- ✓ Diferenças entre estruturas de dados
- ✓ Como analisar algoritmos matematicamente
- ✓ Trade-offs em decisões de design
- ✓ Problemas computacionais reais

**Mensagem Final:** A análise de algoritmos não é apenas teoria acadêmica - é uma **ferramenta prática** que todo programador deve dominar para criar sistemas eficientes e escaláveis!

**Próxima Etapa:** Aplicar esses conceitos em projetos reais e medir a diferença na prática!

